SMX — Spectral Model eXplainability via Perturbação Espectral

Um Guia Teórico e Didático Abrangente

Sumário

1. Introdução e Motivação
2. Visão Geral do Pipeline SMX
3. Pré-processamento Espectral
4. Extração de Zonas Espectrais
5. Agregação de Zonas Espectrais
   - 5.1 Agregadores Simples (Soma, Média, etc.)
   - 5.2 Agregação por PCA — Fundamentação Teórica
6. Geração de Predicados por Quantis
7. Bagging de Predicados
8. Perturbação Espectral — O Coração do Método
   - 8.1 Filosofia da Perturbação
   - 8.2 Modos de Perturbação
   - 8.3 Quais Amostras São Envolvidas?
   - 8.4 Métricas de Impacto — Regressão
   - 8.5 Métricas de Impacto — Classificação
   - 8.6 Algoritmo Completo: calculate_predicate_perturbation
9. Construção do Grafo de Predicados
10. Centralidade Local de Alcance (LRC)
11. Agregação Multi-Semente
12. Mapeamento de Thresholds para o Espaço Natural
13. Reconstrução do Threshold Multivariado
14. Exemplo Completo: Do Espectro à Explicação
15. Comparação com Outros Métodos de Explicabilidade
16. Parâmetros Recomendados
17. Conclusão

1. Introdução e Motivação

Modelos de aprendizado de máquina aplicados a dados espectrais (como espectroscopia de Fluorescência de Raios X — XRF) frequentemente funcionam como "caixas pretas": aprendem relações complexas entre centenas ou milhares de variáveis espectrais e uma resposta de interesse (classe ou valor contínuo), mas não revelam explicitamente **quais regiões do espectro são mais importantes** para as previsões.

O método **SMX (Spectral Model eXplainability)** propõe uma abordagem original para extrair explicações de modelos espectrais. O SMX combina três pilares fundamentais:

1. **Zonas espectrais** — O espectro contínuo é particionado em zonas com significado químico/físico (e.g., picos de emissão de Ca, Fe, Ti em XRF).
2. **Discretização por quantis** — Os valores agregados de cada zona são discretizados em predicados lógicos do tipo "Zona $\leq \tau$" ou "Zona $> \tau$", onde τ é um limiar derivado de quantis.
3. **Teoria de grafos** — Os predicados são organizados em um grafo dirigido, e a centralidade de cada nó (predicado) quantifica sua importância global.

O foco deste documento é a variante do SMX que utiliza **perturbação espectral** como mecanismo para avaliar o impacto de cada predicado. Essa abordagem é uma alternativa à covariância e à informação mútua, oferecendo uma medida causal mais

direta de importância.

---

2. Visão Geral do Pipeline SMX

O pipeline completo do SMX com perturbação segue as seguintes etapas:

```
┌──────────────────────────────────────────────────────────────────────┐
│                        PIPELINE SMX (Perturbação)                    │
├──────────────────────────────────────────────────────────────────────┤
│                                                                      │
│  1. DADOS BRUTOS  ──►  2. PRÉ-PROCESSAMENTO (Poisson + MC)           │
│                              │                                       │
│  3. TREINAMENTO DO MODELO (PLS-DA / SVM / MLP)                       │
│                              │                                       │
│  4. DEFINIÇÃO DAS ZONAS ESPECTRAIS (conhecimento do especialista)    │
│                              │                                       │
│  5. EXTRAÇÃO DAS ZONAS  ──►  6. AGREGAÇÃO POR PCA (scores PC1)       │
│                              │                                       │
│  7. GERAÇÃO DE PREDICADOS (quartis: 0.2, 0.4, 0.6, 0.8)              │
│                              │                                       │
│  8. BAGGING DE PREDICADOS (10 bags × 4 sementes)                     │
│                              │                                       │
│  9. PERTURBAÇÃO ESPECTRAL ──► cálculo do impacto por predicado       │
│                              │                                       │
│ 10. CONSTRUÇÃO DO GRAFO DIRIGIDO                                     │
│                              │                                       │
│ 11. LRC (Local Reaching Centrality) ──► ranking de predicados        │
│                              │                                       │
│ 12. MAPEAMENTO PARA ESPAÇO NATURAL                                   │
│                              │                                       │
│ 13. RECONSTRUÇÃO DO THRESHOLD MULTIVARIADO                           │
│                              │                                       │
│ 14. VISUALIZAÇÃO E INTERPRETAÇÃO                                     │
│                                                                      │
└──────────────────────────────────────────────────────────────────────┘
```

---

3. Pré-processamento Espectral

Antes de aplicar o SMX, os dados espectrais são pré-processados. O pré-processamento padrão utilizado nos experimentos é o **Escalonamento de Poisson com Centragem na Média (MC)**.

3.1 Escalonamento de Poisson

Para dados de contagem (como XRF), a variância de cada variável x_j é proporcional à sua média $\bar{x}_j$. O escalonamento de Poisson corrige essa heteroscedasticidade:

$$ x_{ij}^{\text{Poisson}} = \frac{x_{ij}}{\sqrt{\bar{x}_j}} $$

onde $\bar{x}*j = \frac{1}{n}\sum*{i=1}^{n} x_{ij}$ é a média da variável j no conjunto de calibração.

3.2 Centragem na Média (Mean Centering)

Após o escalonamento de Poisson, subtrai-se a média de cada variável:

$$ x_{ij}^{\text{prep}} = x_{ij}^{\text{Poisson}} - \overline{x_j^{\text{Poisson}}} $$

O resultado é uma matriz $\mathbf{X}^{\text{prep}} \in \mathbb{R}^{n \times p}$ onde n é o número de amostras e p é o número de variáveis espectrais.

> **Importante:** O pré-processamento é ajustado (fit) apenas no conjunto de calibração. Para o conjunto de predição, os mesmos parâmetros (média e escala) são aplicados sem reajuste, garantindo que não há vazamento de informação.

---

4. Extração de Zonas Espectrais

4.1 Conceito

O espectro contínuo $\mathbf{x}*i = [x*{i,\lambda_1}, x_{i,\lambda_2}, \ldots, x_{i,\lambda_p}]$ é particionado em M zonas espectrais, cada uma correspondendo a um intervalo de energia (ou comprimento de onda) com significado físico-químico.

Formalmente, uma zona Z_m é definida como:

$$ Z_m = {j : \lambda_{\text{start}}^{(m)} \leq \lambda_j \leq \lambda_{\text{end}}^{(m)}} $$

onde λ_j é o comprimento de onda (ou energia) da j-ésima coluna.

4.2 Definição pelo Especialista

As zonas são definidas com base no conhecimento do especialista sobre o fenômeno em estudo. Para dados de XRF, cada zona tipicamente corresponde a uma linha de emissão elementar:

```
spectral_cuts = [
    ('Ca ka', 3.50, 3.91),   # Linha K-alfa do Cálcio
    ('Fe ka', 6.15, 6.76),   # Linha K-alfa do Ferro
    ('Zn ka', 8.29, 8.80),   # Linha K-alfa do Zinco
    ...
]
```

4.3 Formalização

Dado o DataFrame $\mathbf{X} \in \mathbb{R}^{n \times p}$, a extração produz um dicionário de sub-matrizes:

$$ \mathbf{X}_{Z_m} \in \mathbb{R}^{n \times d_m}, \quad m = 1, \ldots, M $$

onde $d_m = |Z_m|$ é o número de variáveis na zona m. Note que $\sum_{m=1}^{M} d_m \leq p$, pois pode existir partes do espectro não cobertas por nenhuma zona.

---

5. Agregação de Zonas Espectrais

Cada zona Z_m contém d_m variáveis espectrais. Para gerar predicados, precisamos resumir cada zona em um **único valor escalar** por amostra. Essa etapa é denominada **agregação**.

5.1 Agregadores Simples

Seja $\mathbf{x}*{i}^{(m)} = [x*{i,j_1}, x_{i,j_2}, \ldots, x_{i,j_{d_m}}]$ o vetor de valores da zona m para a amostra i. Os agregadores simples disponíveis são:

Agregador	Fórmula	Descrição
sum	$s_i^{(m)} = \sum_{k=1}^{d_m} x_{i,j_k}$	Soma dos valores da zona
mean	$s_i^{(m)} = \frac{1}{d_m}\sum_{k=1}^{d_m} x_{i,j_k}$	Média aritmética

Agregador	Fórmula	Descrição
median	$s_i^{(m)} = \text{med}(x_{i,j_1}, \ldots, x_{i,j_{d_m}})$	Mediana
max	$s_i^{(m)} = \max_k x_{i,j_k}$	Valor máximo
min	$s_i^{(m)} = \min_k x_{i,j_k}$	Valor mínimo
std	$s_i^{(m)} = \sqrt{\frac{1}{d_m-1}\sum_{k=1}^{d_m}(x_{i,j_k} - \bar{x}_i^{(m)})^2}$	Desvio padrão
var	$s_i^{(m)} = \frac{1}{d_m-1}\sum_{k=1}^{d_m}(x_{i,j_k} - \bar{x}_i^{(m)})^2$	Variância
extreme	$s_i^{(m)} = x_{i,j^}$ *onde* $j^ = \arg\max_k	x_{i,j_k}

O resultado é uma matriz $\mathbf{S} \in \mathbb{R}^{n \times M}$, onde cada coluna m contém os valores agregados da zona Z_m.

5.2 Agregação por PCA — Fundamentação Teórica

A agregação por PCA é a abordagem **recomendada e utilizada em todos os experimentos** do SMX. Ela captura a direção de máxima variância dentro de cada zona, produzindo uma representação mais rica que os agregadores escalares simples.

5.2.1 Fundamentação Matemática da PCA

Para cada zona Z_m, considere a sub-matriz $\mathbf{X}_{Z_m} \in \mathbb{R}^{n \times d_m}$. A PCA com 1 componente realiza os seguintes passos:

Passo 1 — Centralização:

$$ \tilde{\mathbf{X}}*{Z_m} = \mathbf{X}*{Z_m} - \mathbf{1}n \cdot \bar{\mathbf{x}}*{Z_m}^T $$

onde $\bar{\mathbf{x}}*{Z_m} = \frac{1}{n}\sum*{i=1}^{n}\mathbf{x}_i^{(m)} \in \mathbb{R}^{d_m}$ é o vetor de médias da zona.

Passo 2 — Decomposição em Valores Singulares (ou autovalores):

A PCA encontra o vetor de pesos $\mathbf{w}_1^{(m)} \in \mathbb{R}^{d_m}$ que maximiza a variância projetada:

$$ \mathbf{w}*1^{(m)} = \arg\max*{|\mathbf{w}|=1} \text{Var}\left(\tilde{\mathbf{X}}_{Z_m} \mathbf{w}\right) $$

Equivalentemente, $\mathbf{w}*1^{(m)}$ é o autovetor associado ao maior autovalor da matriz de covariância $\hat{\boldsymbol{\Sigma}} = \frac{1}{n-1}\tilde{\mathbf{X}}*{Z_m}^T \tilde{\mathbf{X}}_{Z_m}$.

Passo 3 — Projeção (Scores):

$$ t_i^{(m)} = \left(\mathbf{x}*i^{(m)} - \bar{\mathbf{x}}*{Z_m}\right)^T \mathbf{w}_1^{(m)} $$

O score $t_i^{(m)}$ é a projeção da amostra i na direção de máxima variância da zona m.

Passo 4 — Variância Explicada:

$$ \text{VE}^{(m)} = \frac{\sigma_1^2}{\sum_{k=1}^{d_m} \sigma_k^2} $$

onde σ_1^2 é o maior autovalor. Essa fração indica quanto da variância total da zona é capturada pelo PC1.

5.2.2 Resultado da Agregação PCA

O resultado é um DataFrame $\mathbf{T} \in \mathbb{R}^{n \times M}$ de scores e um dicionário de metadados PCA contendo, para cada zona m:

Componente	Símbolo	Dimensão	Descrição
Loadings	$\mathbf{w}_1^{(m)}$	d_m	Pesos de cada variável no PC1
Média	$\bar{\mathbf{x}}_{Z_m}$	d_m	Vetor de médias da zona
Variância Explicada	$\text{VE}^{(m)}$	escalar	Fração da variância capturada
Colunas	—	d_m	Nomes das variáveis originais

5.2.3 Por que PCA e não Soma?

A agregação por PCA oferece vantagens fundamentais:

1. **Direcionalidade**: O PC1 captura a direção de **máxima diferenciação** entre amostras, ponderando as variáveis de forma ótima.
2. **Invertibilidade**: A transformação PCA é invertível — é possível **reconstruir o limiar (threshold) no espaço espectral original**, gerando um "espectro limiar" (threshold spectrum). Isso é impossível com agregadores simples como soma ou média.
3. **Informação de qualidade**: A variância explicada $\text{VE}^{(m)}$ quantifica quão bem o score resume a informação da zona, permitindo ponderar a importância pela qualidade da representação.

---

6. Geração de Predicados por Quantis

6.1 Conceito

Um **predicado** é uma proposição lógica que particiona as amostras em dois grupos: as que satisfazem a condição e as que não satisfazem. No SMX, os predicados são gerados a partir dos valores agregados das zonas espectrais usando quantis como limiares.

6.2 Definição Formal

Dado o DataFrame de scores agregados $\mathbf{T} \in \mathbb{R}^{n \times M}$ e um conjunto de quantis $\mathcal{Q} = {q_1, q_2, \ldots, q_K}$ (e.g., ${0.2, 0.4, 0.6, 0.8}$), para cada zona m e cada quantil q_k:

1. Calcula-se o valor do quantil:

$$ \tau_{m,k} = Q_{q_k}(t_1^{(m)}, t_2^{(m)}, \ldots, t_n^{(m)}) $$

onde $Q_{q_k}(\cdot)$ é a função quantil empírica de nível q_k.

2. Geram-se **dois predicados** complementares:

$$ P_{m,k}^{\leq}: \quad t_i^{(m)} \leq \tau_{m,k} $$

$$ P_{m,k}^{>}: \quad t_i^{(m)} > \tau_{m,k} $$

6.3 Número Total de Predicados

Para M zonas e K quantis, o número máximo de predicados é:

$$ N_P = 2 \times M \times K $$

Na prática, predicados duplicados (gerados quando diferentes zonas possuem o mesmo valor de quantil) são removidos, resultando em $N_P' \leq N_P$ predicados únicos.

6.4 Matriz Indicadora de Predicados

A matriz indicadora $\mathbf{I} \in {0, 1}^{n \times N_P'}$ é construída onde:

$$ I_{i,j} = \begin{cases} 1 & \text{se a amostra } i \text{ satisfaz o predicado } j \ 0 & \text{caso contrário} \end{cases} $$

Essa matriz indica, para cada par (amostra, predicado), se a condição lógica é cumprida.

6.5 Exemplo Concreto

Suponha a zona "Ca ka" com 4 quantis ${0.2, 0.4, 0.6, 0.8}$:

Quantil	τ	Predicado $\leq$	Predicado $>$
0.2	-3.42	Ca ka $\leq$ -3.42	Ca ka $>$ -3.42
0.4	-1.15	Ca ka $\leq$ -1.15	Ca ka $>$ -1.15
0.6	0.87	Ca ka $\leq$ 0.87	Ca ka $>$ 0.87
0.8	2.56	Ca ka $\leq$ 2.56	Ca ka $>$ 2.56

Cada predicado define um subconjunto de amostras. Por exemplo, "Ca ka $\leq$ -3.42" seleciona as ~20% amostras com menor valor agregado na zona do Cálcio.

---

7. Bagging de Predicados

7.1 Motivação

O bagging (Bootstrap AGGregatING) é utilizado para:

- **Reduzir a variância** do ranking de importância dos predicados
- **Aumentar a robustez** contra outliers e flutuações amostrais
- **Criar diversidade** na avaliação dos predicados

7.2 Estratégia de Amostragem

O bagging no SMX opera em **duas dimensões** independentes:

1. **Amostragem de linhas (amostras)**: Controlada por `sample_bagging`
2. **Amostragem de colunas (predicados)**: Controlada por `predicate_bagging`

Nos experimentos do SMX, a configuração padrão é:

- `sample_bagging=True`: Sorteia-se um subconjunto de amostras para cada bag
- `predicate_bagging=False`: Todos os predicados são usados em todos os bags

7.3 Algoritmo

Para cada bag $b = 1, \ldots, B$:

1. **Seleção de amostras**: Sorteia-se um subconjunto $\mathcal{S}_b \subset {1, \ldots, n}$ de tamanho n_b (tipicamente 80% do total), **sem reposição** (subamostragem).

2. **Seleção de predicados**: Utiliza-se todos os N_P' predicados (quando `predicate_bagging=False`).

3. **Filtragem**: Para cada predicado P_j, filtra-se os índices de amostras em $\mathcal{S}_b$ que satisfazem P_j:

$$ \mathcal{S}_b^{(j)} = {i \in \mathcal{S}*b : I{i,j} = 1} $$

4. **Validação**: Se $|\mathcal{S}*b^{(j)}| < n{\min}$ (e.g., 20% do total), o predicado é descartado deste bag por cobertura insuficiente.

5. **Armazenamento**: Para cada predicado válido, armazena-se um DataFrame com:

- `Zone_Sum`: valor agregado da zona para as amostras satisfeitas
- `Predicted_Y`: predição do modelo para essas amostras
- `Sample_Index`: índices originais das amostras

7.4 Multi-Semente

O procedimento completo de bagging é repetido com diferentes sementes aleatórias (tipicamente ${0, 1, 2, 3}$), e os resultados são agregados posteriormente. Isso confere robustez adicional ao ranking final.

7.5 Parâmetros Típicos

Parâmetro	Valor Padrão	Descrição
`n_bags`	10	Número de bags por semente
`n_samples_per_bag`	$0.8 \times n$	Amostras por bag
`min_samples_per_predicate`	$0.2 \times n$	Mínimo de amostras para validação
`replace`	`False`	Subamostragem (sem reposição)
`sample_bagging`	`True`	Amostragem de linhas ativada
`predicate_bagging`	`False`	Todos os predicados em todos os bags

---

8. Perturbação Espectral — O Coração do Método

8.1 Filosofia da Perturbação

A ideia central da perturbação espectral é simples e poderosa:

> **Se uma zona espectral é importante para a previsão do modelo, então "destruir" (perturbar) a informação nessa zona deve causar uma mudança significativa nas previsões.**

Diferentemente da covariância ou informação mútua (que medem associação estatística entre o valor agregado da zona e a previsão), a perturbação mede diretamente o **impacto causal** da informação espectral sobre o modelo. Essa abordagem é análoga ao conceito de *feature importance by permutation*, mas adaptada ao contexto espectral com duas diferenças fundamentais:

1. **Perturbação por substituição** ao invés de permutação: os valores da zona são substituídos por um valor fixo ou uma estatística (mediana, média, etc.), em vez de serem permutados entre amostras.
2. **Granularidade de predicado**: a importância é calculada não para a zona inteira, mas para cada predicado — ou seja, considerando apenas o subconjunto de amostras que satisfaz a condição do predicado.

8.2 Modos de Perturbação

O SMX oferece cinco modos de perturbação, controlados pelo parâmetro `perturbation_mode`:

8.2.1 Modo `constant` (Constante)

Todas as variáveis da zona são substituídas por um valor fixo c:

$$ \tilde{x}_{i,j} = c, \quad \forall j \in Z_m $$

Tipicamente $c = 0$, o que efetivamente "zera" a informação da zona.

8.2.2 Modo `mean` (Média)

Cada variável da zona é substituída pela sua média:

$$ \tilde{x}_{i,j} = \bar{x}_j = \frac{1}{n_{\text{src}}}\sum_{k \in \mathcal{S}_{\text{src}}} x_{k,j}, \quad \forall j \in Z_m $$

onde $\mathcal{S}_{\text{src}}$ é o conjunto fonte para cálculo da estatística (ver Seção 8.2.6).

8.2.3 Modo `median` (Mediana) ⭑ *Recomendado*

Cada variável da zona é substituída pela sua mediana:

$$ \tilde{x}_{i,j} = \text{med}_j = \text{mediana}\{x_{k,j} : k \in \mathcal{S}_{\text{src}}\}, \quad \forall j \in Z_m $$

Este é o modo utilizado em **todos os experimentos** do SMX. A mediana é preferida à média por ser mais robusta a outliers.

8.2.4 Modo `min` (Mínimo)

$$ \tilde{x}_{i,j} = \min_{k \in \mathcal{S}_{\text{src}}} x_{k,j}, \quad \forall j \in Z_m $$

8.2.5 Modo `max` (Máximo)

$$ \tilde{x}_{i,j} = \max_{k \in \mathcal{S}_{\text{src}}} x_{k,j}, \quad \forall j \in Z_m $$

8.2.6 Fonte das Estatísticas (`stats_source`)

Quando o modo de perturbação é baseado em uma estatística (média, mediana, min, max), é necessário definir **qual conjunto de amostras** é usado para calcular essa estatística:

- `stats_source='full'` ⭑: Usa **todo o conjunto de calibração** $\mathbf{X}^{\text{prep}}$ para calcular a estatística. Esse é o padrão e a abordagem usada nos experimentos.
- `stats_source='predicate'`: Usa apenas as **amostras que satisfazem o predicado** atual.

A diferença é sutil, porém importante. Com `'full'`, a perturbação substitui os valores da zona pela estatística da população geral — uma perturbação em direção ao "comportamento médio". Com `'predicate'`, a perturbação é mais localizada.

8.3 Quais Amostras São Envolvidas?

Um ponto crucial da perturbação no SMX é que ela **não opera sobre todas as amostras do dataset** de uma vez. O processo envolve várias camadas de filtragem:

Camada 1 — Bagging (Seleção de Amostras por Bag)

Para cada bag b, um subconjunto $\mathcal{S}_b$ de amostras é selecionado (80% do total, sem reposição).

Camada 2 — Predicado (Seleção por Condição Lógica)

Dentro do bag b, para cada predicado P_j, apenas as amostras que **satisfazem** o predicado são utilizadas:

$$ \mathcal{S}_{b}^{(j)} = \{i \in \mathcal{S}_b : t_i^{(m)} \leq \tau \text{ (ou } > \tau \text{)}\} $$

Camada 3 — Perturbação e Previsão

A perturbação é aplicada **apenas às colunas espectrais da zona relevante**, mantendo intactas todas as demais variáveis:

$$ \tilde{\mathbf{x}}_i = \begin{cases} \text{estatística}(x_{\cdot,j}) & \text{se } j \in Z_m \\ x_{i,j} & \text{se } j \notin Z_m \end{cases} $$

Isso garante que estamos medindo o impacto da zona Z_m de forma isolada.

Resumo Visual

```
Todo o dataset de calibração (n amostras)
    │
    ├── Bag 1: subconjunto S₁ (~80% das amostras)
    │   │
    │   ├── Predicado "Ca ka ≤ -1.15": amostras de S₁ satisfazendo a condição
    │   │   └── Perturbação: zerar/mediana a zona "Ca ka" → prever → medir impacto
    │   │
    │   ├── Predicado "Fe ka > 3.22": amostras de S₁ satisfazendo a condição
    │   │   └── Perturbação: zerar/mediana a zona "Fe ka" → prever → medir impacto
    │   │
    │   └── ...
    │
    ├── Bag 2: subconjunto S₂ (~80% das amostras)
    │   └── ...
    │
    └── ...
```

8.4 Métricas de Impacto — Regressão

Quando o modelo é tratado como regressor (e.g., PLS-DA com saída contínua entre 0 e 1, ou PLS-R), utilizam-se métricas contínuas para quantificar o impacto da perturbação. Seja $\hat{y}_i$ a previsão original e $\hat{y}_i^{\text{pert}}$ a previsão após perturbação da zona.

8.4.1 `mean_abs_diff` — Diferença Absoluta Média ⋆ *Padrão para regressão*

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} |\hat{y}_i - \hat{y}_i^{\text{pert}}| $$

Interpretação: Mede a magnitude média da mudança na previsão. Valores altos indicam que a zona é importante para o modelo. Essa métrica ignora a direção da mudança.

Propriedades:

- Sempre ≥ 0
- Insensível à direção da perturbação
- Escala: mesma unidade da variável resposta

8.4.2 `mean_diff` — Diferença Média (com sinal)

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} (\hat{y}_i - \hat{y}_i^{\text{pert}}) $$

Interpretação: Se positivo, a perturbação tende a **reduzir** as previsões; se negativo, tende a **aumentá-las**. Permite identificar a **direção** do impacto.

Nota: Para fins de ranking, utiliza-se $|\text{Imp}(P_j)|$.

8.4.3 `mean_relative_dev` — Desvio Relativo Médio

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} \frac{\hat{y}_i^{\text{pert}} - \hat{y}_i}{\hat{y}_i} $$

Interpretação: Expressa a mudança como fração da previsão original. Útil quando a escala absoluta das previsões varia significativamente.

Cuidado: Pode gerar instabilidades quando $\hat{y}_i \approx 0$. Valores nulos são tratados como `NaN` e excluídos do cálculo.

8.5 Métricas de Impacto — Classificação

Quando o modelo é utilizado como classificador (e.g., MLP, SVM), métricas específicas para classificação estão disponíveis.

8.5.1 `prediction_change_rate` — Taxa de Mudança de Predição

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} \mathbb{1}[\hat{c}_i \neq \hat{c}_i^{\text{pert}}] $$

onde $\hat{c}_i$ e $\hat{c}_i^{\text{pert}}$ são as classes preditas antes e após a perturbação, e $\mathbb{1}[\cdot]$ é a função indicadora.

Interpretação: Proporção de amostras que mudaram de classe. Varia de 0 (nenhuma mudou) a 1 (todas mudaram). **Não requer rótulos verdadeiros.**

8.5.2 `accuracy_drop` — Queda de Acurácia

$$ \text{Imp}(P_j) = \text{Acc}(\hat{\mathbf{c}}, \mathbf{y}) - \text{Acc}(\hat{\mathbf{c}}^{\text{pert}}, \mathbf{y}) $$

Interpretação: Diferença na acurácia antes e após perturbação. Valores positivos indicam degradação. **Requer rótulos verdadeiros ($\mathbf{y}$).**

8.5.3 `f1_drop` — Queda do F1-Score

$$ \text{Imp}(P_j) = F_1(\hat{\mathbf{c}}, \mathbf{y}) - F_1(\hat{\mathbf{c}}^{\text{pert}}, \mathbf{y}) $$

Interpretação: Análogo à queda de acurácia, mas usando F1-score (média ponderada para suporte de classes desbalanceadas). **Requer rótulos verdadeiros.**

8.5.4 `probability_shift` — Deslocamento de Probabilidade ⭑ ***Padrão para classificação***

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} \frac{1}{2}\sum_{c=1}^{C} |p_{i,c} - p_{i,c}^{\text{pert}}| $$

onde $p_{i,c} = P(\hat{c}_i = c | \mathbf{x}_i)$ são as probabilidades preditas pelo modelo e C é o número de classes.

Interpretação: Mede quanto as probabilidades de classe mudam em média após a perturbação. A divisão por 2 normaliza para o fato de que, em classificação binária, se a probabilidade de uma classe aumenta em δ, a da outra diminui em δ.

Requer: Modelo com método `predict_proba()` (e.g., SVC com `probability=True`, MLP, RandomForest).

Propriedades:

- Varia de 0 a 1
- Mais sensível que `prediction_change_rate` (detecta mudanças graduais nas probabilidades, mesmo que a classe predita não mude)
- Não requer rótulos verdadeiros

8.5.5 `decision_function_shift` — Deslocamento da Função de Decisão

$$ \text{Imp}(P_j) = \frac{1}{|\mathcal{S}|}\sum_{i \in \mathcal{S}} |d(\mathbf{x}_i) - d(\tilde{\mathbf{x}}_i)| $$

onde $d(\mathbf{x})$ é a função de decisão do modelo (e.g., distância ao hiperplano para SVM).

Requer: Modelo com método `decision_function()` (e.g., SVC, LinearSVC, LogisticRegression).

8.6 Algoritmo Completo: `calculate_predicate_perturbation`

O algoritmo completo da perturbação espectral por predicado é:

```
ALGORITMO: Perturbação Espectral por Predicado
═══════════════════════════════════════════════

ENTRADA:
  - estimator: modelo treinado
  - X_prep: dados pré-processados (n × p)
  - folds_struct: estrutura de bags {Bag_k: {regra: DataFrame}}
  - predicates_df: DataFrame de predicados
  - spectral_cuts: definição das zonas [(nome, início, fim)]
  - aim: 'regression' ou 'classification'
  - perturbation_mode: 'constant', 'mean', 'median', 'min', 'max'
  - metric: métrica de impacto selecionada

SAÍDA:
  - metrics_dict: {Bag_k: DataFrame(Predicate, Perturbation)}

PARA CADA bag (fold) na estrutura:
  PARA CADA predicado P_j no bag:

    1. Extrair índices das amostras que satisfazem P_j
       S_j ← {i : amostra i satisfaz P_j no bag}

    2. Identificar a zona espectral Z_m associada a P_j
       zone_cols ← colunas de X_prep pertencentes a Z_m

    3. Construir subconjunto de dados original
       X_eval ← X_prep[S_j, :]  (apenas amostras do predicado)

    4. Aplicar perturbação
       X_pert ← X_eval.copy()
       SE perturbation_mode == 'constant':
         X_pert[:, zone_cols] ← perturbation_value
       SENÃO:
         stats ← calcular_estatística(X_fonte[:, zone_cols])
         X_pert[:, zone_cols] ← stats

    5. Obter previsões originais e perturbadas
       y_orig ← estimator.predict(X_eval)
       y_pert ← estimator.predict(X_pert)

    6. Calcular importância segundo a métrica selecionada
       imp ← calcular_métrica(y_orig, y_pert, y_true, metric)

    7. Armazenar importância
       fold_metrics[P_j] ← imp

  FIM PARA
  metrics_dict[bag] ← DataFrame(fold_metrics)
FIM PARA

RETORNAR metrics_dict
```

8.7 Compatibilidade de Métricas com Modelos

Modelo	`prediction_change_rate`	`accuracy_drop`	`probability_shift`	`decision_function_shift`
SVC	✓	✓	✓ (`probability=True`)	✓

Modelo	`prediction_change_rate`	`accuracy_drop`	`probability_shift`	`decision_function_shift`
LinearSVC	✓	✓	✗	✓
RandomForest	✓	✓	✓	✗
LogisticRegression	✓	✓	✓	✓
KNeighbors	✓	✓	✓	✗
PLSRegression	regression metrics	regression metrics	✗	✗
MLP	✓	✓	✓	✗

9. Construção do Grafo de Predicados

9.1 Motivação

As importâncias calculadas pela perturbação (ou covariância/informação mútua) são **locais** — atribuídas a cada predicado individualmente dentro de cada bag. Para obter uma visão **global** da importância, o SMX constrói um **grafo dirigido** que codifica as relações entre predicados e as conecta a nós terminais de classe.

9.2 Estrutura do Grafo

O grafo $G = (V, E)$ é um **dígrafo ponderado** com:

- **Nós terminais**: `Class_A` e `Class_B` (as classes do problema)
- **Nós de predicado**: cada predicado válido que aparece em pelo menos um bag
- **Arestas dirigidas**: conexões entre predicados consecutivos, ponderadas pela importância

9.3 Algoritmo de Construção

Para cada bag b:

1. **Ordenação**: Os predicados do bag são ordenados em ordem **decrescente** de importância (valor da métrica de perturbação).

2. **Arestas entre consecutivos**: São criadas arestas direcionadas entre predicados consecutivos na ordenação:

$$ P_1^{(b)} \xrightarrow{w_1} P_2^{(b)} \xrightarrow{w_2} P_3^{(b)} \xrightarrow{w_3} \ldots $$

onde w_i é o valor da métrica de perturbação do predicado **de origem** (source).

3. **Ponderação pela Variância Explicada** (opcional, mas ativado por padrão): Os pesos das arestas são multiplicados pela variância explicada pelo PC1 da zona correspondente ao predicado de origem:

$$ w_i^{\text{ponderado}} = w_i \times \text{VE}^{(m_i)} $$

Isso faz com que zonas cujo PC1 captura menor parcela da variância tenham seus pesos reduzidos — uma penalização pela qualidade da representação.

4. **Conexão terminal**: O último predicado da sequência é conectado ao nó terminal correspondente à **classe majoritária** entre as amostras que satisfazem aquele predicado:

$$ P_{\text{last}}^{(b)} \xrightarrow{w_{\text{last}}} \text{Class}_{c^*} $$

onde $c^* = \arg\max_c \sum_{i \in \mathcal{S}} \mathbb{1}[\hat{c}_i = c]$.

5. **Acumulação**: Se uma aresta (u, v) já existe no grafo (de bags anteriores), o peso é **acumulado** (somado):

$$ w(u, v) \leftarrow w(u, v) + w_{\text{novo}} $$

9.4 Resolução de Arestas Bidirecionais

Após processar todos os bags, podem existir arestas bidirecionais: $u \rightarrow v$ e $v \rightarrow u$. Essas são resolvidas mantendo apenas a direção com **maior peso acumulado**:

$$ \text{Se } w(u \rightarrow v) > w(v \rightarrow u): \text{remover } v \rightarrow u $$

Em caso de empate ($w(u \rightarrow v) = w(v \rightarrow u)$), a decisão é aleatória (controlada por `random_state`).

9.5 Resultado

O grafo final é um `nx.DiGraph` (NetworkX) com:

- **Nós**: predicados + dois nós terminais de classe
- **Arestas**: ponderadas pela importância acumulada ao longo de todos os bags
- **Topologia**: reflete a frequência e consistência com que certos predicados aparecem juntos e se conectam a certas classes

---

10. Centralidade Local de Alcance (LRC)

10.1 Conceito

A **Local Reaching Centrality (LRC)** quantifica a importância de um nó com base na sua capacidade de alcançar outros nós no grafo, levando em conta os pesos das arestas. Nós com alto LRC são "hubs" — predicados centrais que conectam diferentes partes do grafo.

10.2 Definição Formal

Para um grafo dirigido $G = (V, E)$ com pesos $w: E \rightarrow \mathbb{R}^+$, a LRC do nó v é definida como:

$$ \text{LRC}(v) = \frac{1}{|V| - 1} \sum_{u \in V \setminus {v}} \frac{d(v, u)}{D} $$

onde:

- $d(v, u)$ é a distância (caminho mais curto ponderado) de v a u
- D é o diâmetro ponderado do grafo (maior distância entre quaisquer dois nós alcançáveis)

Na implementação do NetworkX, `nx.local_reaching_centrality(G, v, weight='weight')` calcula essa medida considerando os pesos das arestas.

10.3 Interpretação no Contexto SMX

- **Alto LRC**: O predicado está bem posicionado no grafo, conectando-se a muitos outros predicados com arestas de alto peso. Indica alta importância global.
- **Baixo LRC**: O predicado é periférico — conecta-se a poucos nós ou com baixo peso. Menor importância global.

10.4 Extração do Ranking

O resultado é um DataFrame ordenado por LRC (decrescente):

Node	Local_Reaching_Centrality	Zone	Threshold	Operator
Fe ka $>$ 1.23	0.847	Fe ka	1.23	$>$
Ca ka $\leq$ -0.56	0.723	Ca ka	-0.56	$\leq$
...	...	...	...	...

11. Agregação Multi-Semente

11.1 Procedimento

O pipeline completo (bagging → perturbação → grafo → LRC) é repetido para múltiplas sementes aleatórias (tipicamente ${0, 1, 2, 3}$). Os valores de LRC de todas as sementes são então **agregados pela média**:

$$ \overline{\text{LRC}}(v) = \frac{1}{|\mathcal{R}|}\sum_{r \in \mathcal{R}} \text{LRC}_r(v) $$

onde $\mathcal{R}$ é o conjunto de sementes.

11.2 Ranking por Zona

Para o ranking final, seleciona-se o **predicado de maior LRC médio por zona**, eliminando duplicidades:

$$ P_m^* = \arg\max_{P_j : \text{zona}(P_j) = Z_m} \overline{\text{LRC}}(P_j) $$

Isso produz um ranking de zonas espectrais pelo seu predicado mais relevante.

---

12. Mapeamento de Thresholds para o Espaço Natural

12.1 O Problema

Os predicados são gerados no **espaço pré-processado** (Poisson + MC). Os limiares τ nesse espaço não têm interpretação direta para o especialista. É necessário mapeá-los de volta para o **espaço natural** (escala original dos dados).

12.2 Método: Amostra Mais Próxima

A função `map_thresholds_to_natural` utiliza uma abordagem de **mapeamento por amostra mais próxima**:

1. **PCA é ajustada no espaço natural**: Os dados originais (sem pré-processamento) passam pela mesma extração de zonas e agregação PCA, produzindo scores no espaço natural $t_i^{(m,\text{nat})}$.
2. **Para cada predicado com limiar τ^{prep}**: Encontra-se a amostra cujo score no espaço pré-processado é mais próximo do limiar:

$$ i^* = \arg\min_i |t_i^{(m,\text{prep})} - \tau^{\text{prep}}| $$

3. **O score natural dessa amostra é o limiar natural**:

$$ \tau^{\text{nat}} = t_{i^*}^{(m,\text{nat})} $$

4. **Erro de aproximação**: Também é registrado o erro $\epsilon = |t_{i^*}^{(m,\text{prep})} - \tau^{\text{prep}}|$.

12.3 Limitações

- A qualidade do mapeamento depende da densidade de amostras ao redor do limiar
- Para amostras esparsas, o erro de aproximação pode ser significativo
- O método assume que a **ordenação relativa** das amostras é preservada entre os espaços pré-processado e natural (para limiares baseados em quantis, isso é geralmente verdadeiro)

---

13. Reconstrução do Threshold Multivariado — Do Score ao Espectro

13.1 O Conceito de Threshold Multivariado

Esta é uma das contribuições mais inovadoras do SMX com agregação PCA. Enquanto um predicado como "Fe ka > 1.23" define um limiar sobre um **valor escalar** (o score PC1), o threshold multivariado reconstrói esse limiar no **espaço espectral**

original, gerando um **espectro limiar** — um vetor em $\mathbb{R}^{d_m}$ que define a fronteira do predicado na dimensão espectral completa da zona.

13.2 Fundamentação Matemática

13.2.1 Da Projeção à Reconstrução

Lembre que a PCA projeta os dados centrados sobre o vetor de pesos:

$$ t_i^{(m)} = (\mathbf{x}*i^{(m)} - \bar{\mathbf{x}}*{Z_m})^T \mathbf{w}_1^{(m)} $$

Para reconstruir um score q (no caso, o threshold τ) de volta ao espaço original, invertemos a projeção. Na PCA com 1 componente, a reconstrução exata é:

$$ \hat{\mathbf{x}}^{(m)} = \bar{\mathbf{x}}_{Z_m} + q \cdot \mathbf{w}_1^{(m)} $$

13.2.2 O Espectro Limiar (Threshold Spectrum)

Substituindo q pelo valor do threshold τ, obtemos o **espectro limiar**:

$$ \boldsymbol{\tau}^{\text{espectro}} = \bar{\mathbf{x}}_{Z_m} + \tau \cdot \mathbf{w}_1^{(m)} $$

onde:

- $\bar{\mathbf{x}}_{Z_m} \in \mathbb{R}^{d_m}$ é o vetor de médias da zona (centro dos dados)
- $\tau \in \mathbb{R}$ é o valor do threshold (escalar, no espaço de scores)
- $\mathbf{w}_1^{(m)} \in \mathbb{R}^{d_m}$ é o vetor de loadings do PC1 (direção de máxima variância)
- $\boldsymbol{\tau}^{\text{espectro}} \in \mathbb{R}^{d_m}$ é o espectro resultante

13.2.3 Interpretação Geométrica

O espectro limiar é o **ponto no espaço espectral que está exatamente sobre a fronteira do predicado**. Geometricamente:

- $\bar{\mathbf{x}}_{Z_m}$ é o centroide da nuvem de pontos (amostras) no espaço da zona
- $\mathbf{w}_1^{(m)}$ define a direção principal de variação
- $\tau \cdot \mathbf{w}_1^{(m)}$ é o deslocamento ao longo dessa direção até o threshold
- O espectro limiar é, portanto, o centroide deslocado na direção do PC1

```
                    ↑ w₁
                    |         Amostras
                    |    o      o
←————————————●————|——o——●——o————→ PC1
        τ<0    |    |      centro   τ>0
               |    |   (média)
  Threshold    |
  espectro     |
```

13.2.4 Para o Espaço Natural

Para obter o threshold multivariado no espaço natural (não pré-processado), utiliza-se a PCA ajustada nos dados originais:

$$ \boldsymbol{\tau}*{\text{nat}}^{\text{espectro}} = \bar{\mathbf{x}}*{Z_m}^{\text{nat}} + \tau^{\text{nat}} \cdot \mathbf{w}_{1,\text{nat}}^{(m)} $$

onde $\bar{\mathbf{x}}*{Z_m}^{\text{nat}}$ e $\mathbf{w}*{1,\text{nat}}^{(m)}$ são a média e os loadings da PCA ajustada no espaço natural.

13.3 Significado Prático

O espectro limiar pode ser sobreposto aos espectros individuais das amostras em uma visualização:

- **Amostras acima do espectro limiar**: tendem a satisfazer o predicado "$> \tau$"
- **Amostras abaixo do espectro limiar**: tendem a satisfazer o predicado "$\leq \tau$"

Para um especialista em XRF, por exemplo, o espectro limiar da zona "Fe ka" mostra a **intensidade mínima de fluorescência do Ferro** que diferencia os dois grupos de amostras. Isso traduz uma regra estatística abstrata em uma informação espectroscópica concreta e interpretável.

13.4 Vantagem sobre Agregadores Simples

Com agregadores como soma ou média, o threshold é um número ($\tau = 25.3$) sem correspondência espectral. Não há como saber **como** aquele valor se distribui entre as variáveis da zona. Com PCA:

Aspecto	Soma/Média	PCA
Threshold	Escalar único ($\tau = 25.3$)	Vetor espectral ($\boldsymbol{\tau} \in \mathbb{R}^{d_m}$)
Interpretação	"A soma dos valores é 25.3"	"O espectro limiar tem esta forma"
Visualização	Linha horizontal	Espectro sobreponível aos dados
Ponderação	Todas variáveis iguas	Ponderação ótima (PC1 loadings)
Informação de qualidade	Não	Variância explicada

14. Exemplo Completo: Do Espectro à Explicação

Para consolidar toda a teoria, vamos acompanhar o pipeline completo para um dataset real de XRF de cédulas bancárias (*bank notes*).

Passo 1 — Dados

```
# 150 amostras (75 autênticas + 75 falsas), 997 variáveis espectrais (2.74 - 22.71 keV)
data = pd.read_csv('real_datasets/xrf/bank_notes.csv', sep=';')
```

Passo 2 — Pré-processamento Poisson + MC

$$ \mathbf{X}^{\text{prep}} = \frac{\mathbf{X}}{\sqrt{\bar{\mathbf{x}}}} - \overline{\left(\frac{\mathbf{X}}{\sqrt{\bar{\mathbf{x}}}}\right)} $$

Passo 3 — Modelo PLS-DA

```
pls_model = pls_optimized(X_prep, y, LVmax=4, aim='classification')
y_pred_cont = plsda_results[5].iloc[:, -1]  # saída contínua [0, 1]
```

Passo 4 — Definição de 15 zonas espectrais

```
spectral_cuts = [
    ('Ar ka + Ag L', 2.76, 3.47),
    ('Ca ka', 3.50, 3.91),
    ('Fe ka', 6.15, 6.76),
```

```
    # ... 15 zonas no total
]
```

Passo 5 — Extração e Agregação PCA

```
zones = extract_spectral_zones(X_prep, spectral_cuts)      # 15 sub-DataFrames
scores, pca_info = aggregate_spectral_zones_pca(zones)      # 15 scores PC1
```

Resultado: DataFrame $\mathbf{T}$ com n linhas e 15 colunas (uma por zona).

Passo 6 — Geração de Predicados

```
pred_df, indicator_df, cooccurrence = predicates_by_quantiles(scores, [0.2, 0.4, 0.6, 0.8])
```

Resultado: Até $2 \times 15 \times 4 = 120$ predicados (após remoção de duplicatas).

Passo 7 — Bagging (para cada semente)

```
bags = bagging_predicates(scores, y_pred_cont, pred_df,
    n_bags=10, n_samples_per_bag=int(0.8*n), replace=False,
    sample_bagging=True, predicate_bagging=False, random_seed=seed)
```

Passo 8 — Perturbação

```
pert_results = calculate_predicate_perturbation(
    estimator=pls_model,
    Xcalclass_prep=X_prep,
    folds_struct=bags,
    predicates_df=pred_df,
    spectral_cuts=spectral_cuts,
    perturbation_mode='median',    # ← mediana
    stats_source='full',           # ← todo o dataset
    aim='regression',
    metric='mean_abs_diff'         # ← |y_orig - y_pert|
)
```

O que acontece internamente para o predicado "Ca ka ≤ -1.15" no Bag_3:

1. Identifica ~18 amostras no Bag_3 que satisfazem "Ca ka ≤ -1.15"
2. Localiza as 21 colunas espectrais da zona Ca ka (3.50 - 3.91 keV)
3. Cria cópia dos dados das 18 amostras
4. Substitui as 21 colunas pela **mediana** (calculada sobre todas as n amostras)
5. Prediz com `pls_model.predict()` antes e depois
6. Calcula $\frac{1}{18}\sum_{i=1}^{18}|\hat{y}_i - \hat{y}_i^{\text{pert}}| = 0.0342$

Passo 9 — Grafo

```
DG = build_predicate_graph(bags, pert_results,
    metric_column='Perturbation', var_exp=True, pca_info_dict=pca_info)
```

Passo 10 — LRC

```
lrc_df = calculate_lrc_single_graph(DG, pred_df)
```

Passo 11 — Agregação e Mapeamento Natural

```
# Agregar LRC de 4 sementes
lrc_avg = lrc_all.groupby('Node')['Local_Reaching_Centrality'].mean()

# Mapear para espaço natural
zones_nat = extract_spectral_zones(X_original, spectral_cuts)
scores_nat, pca_nat = aggregate_spectral_zones_pca(zones_nat)
lrc_natural = map_thresholds_to_natural(lrc_df, scores, scores_nat)
```

Passo 12 — Threshold Multivariado

```
# Para o predicado mais importante (e.g., "Fe ka > 1.23")
threshold_spectrum = reconstruct_threshold_to_spectrum(
    threshold_value=1.23_natural,   # threshold no espaço natural
    zone_name='Fe ka',
    pca_info_dict=pca_nat
)
# threshold_spectrum é um vetor de ~30 valores (um para cada energia na zona Fe ka)
```

Passo 13 — Visualização

O espectro limiar (linha tracejada vermelha) é sobreposto aos espectros das amostras:

- Espectros de cédulas autênticas (Classe A) em dourado
- Espectros de cédulas falsas (Classe B) em azul
- O espectro limiar separa visualmente os dois grupos na zona do Ferro

---

15. Comparação com Outros Métodos de Explicabilidade

O SMX é comparado com métodos tradicionais de explicabilidade de modelos espectrais por meio do **RBO (Rank-Biased Overlap)**, que quantifica a similaridade entre rankings de zonas produzidos por diferentes métodos.

Método	Tipo	Dependência do Modelo	Granularidade
SMX-Perturbação	Model-agnostic (requer `predict`)	Indireta (via previsões)	Predicado (zona + limiar)
SMX-Covariância	Model-agnostic	Indireta (associação estatística)	Predicado
SHAP	Model-agnostic	Indireta	Variável individual

Método	Tipo	Dependência do Modelo	Granularidade
VIP Scores	Model-specific (PLS)	Direta (pesos do modelo)	Variável individual
Coeficientes de Regressão	Model-specific (PLS)	Direta	Variável individual
Permutation Importance	Model-agnostic	Indireta	Variável individual

Vantagens do SMX-Perturbação

1. **Interpretabilidade química**: Rankings em nível de zona (com significado químico), não de variáveis isoladas.
2. **Threshold multivariado**: Possibilidade única de reconstruir o limiar como espectro, viabilizada pela agregação PCA.
3. **Robustez via bagging e multi-semente**: Reduz a variância do ranking.
4. **Flexibilidade**: Funciona com qualquer modelo (PLS, SVM, MLP, etc.) e em contextos de regressão e classificação.
5. **Causalidade direta**: A perturbação mede o impacto causal real sobre as previsões, ao contrário da covariância que mede apenas associação.

---

16. Parâmetros Recomendados

Com base nos experimentos realizados em 8 datasets de XRF com 3 tipos de modelo:

Parâmetro	Valor Recomendado	Justificativa
Quantis	${0.2, 0.4, 0.6, 0.8}$	Boa cobertura da distribuição
`n_bags`	10	Equilíbrio entre robustez e custo
`n_samples_per_bag`	80% de n	Representatividade sem excesso
`min_samples_per_predicate`	20% de n	Garantia de cobertura mínima
`replace`	`False`	Subamostragem preferida a bootstrap
`sample_bagging`	`True`	Ativado para diversidade
`predicate_bagging`	`False`	Todos os predicados avaliados em cada bag
Sementes aleatórias	${0, 1, 2, 3}$	4 repetições para robustez
`perturbation_mode`	`'median'`	Robusta a outliers
`stats_source`	`'full'`	Estatísticas da população inteira
`metric` (regressão)	`'mean_abs_diff'`	Magnitude do impacto, sem viés direcional
`metric` (classificação)	`'probability_shift'`	Sensível a mudanças graduais
`var_exp`	`True`	Ponderar pela qualidade da representação PCA
Threshold covariance	0.01	Filtro mínimo para covariância
Agregação LRC	Média entre sementes	Estável e representativa
RBO	$p=0.7, k=10$	Foco no topo do ranking

---

17. Conclusão

O método SMX com perturbação espectral oferece um framework completo para a explicabilidade de modelos espectrais. Suas principais contribuições são:

1. **Uma nova filosofia de explicabilidade**: Combinar zonas espectrais com significado físico-químico, discretização por quantis, e teoria de grafos para produzir explicações que respeitam a semântica do domínio.

2. **Perturbação como medida de importância**: Substituir informação espectral por o valor da mediana (ou outro estatístico) e medir o impacto nas previsões do modelo proporciona uma medida quasi-causal da relevância de cada zona espectral.

3. **O threshold multivariado**: Através da agregação PCA, o limiar escalar de um predicado pode ser reconstruído como um **espectro limiar** no espaço original — uma capacidade única que transforma regras abstratas em informação espectroscópica concreta e visualizável.

4. **Robustez estatística**: O uso de bagging, múltiplas sementes, e agregação via LRC em grafos dirigidos confere estabilidade ao ranking de importância, reduzindo a sensibilidade a ruído e a flutuações amostrais.

5. **Flexibilidade**: O método é model-agnostic (funciona com PLS, SVM, MLP e qualquer modelo com `predict()`) e suporta tanto regressão quanto classificação com métricas apropriadas.

O SMX conecta, portanto, a análise exploratória de dados espectrais, a modelagem preditiva, e a interpretabilidade de modelos em um pipeline unificado, gerando explicações que são tanto estatisticamente rigorosas quanto quimicamente significativas.

Documento gerado como referência teórica e didática do método SMX (Spectral Model eXplainability) com foco na abordagem de perturbação espectral. Baseado na análise do repositório SMX e seus experimentos com 8 datasets de XRF utilizando modelos PLS-DA, SVM e MLP.